

דוח עבודת למידת מכונה - חיזוי דירוגי סרטים

מגישים : מאיה הלוי 212074736 | עידן וידר 315143305

1. תיאור הדאטה המעובד וטבלת הפיצ'רים

סט הנתונים המקורי כולל 133,884 סרטים עם 13 עמודות. לאחר העשרת נתונים, הנדסת פיצ'רים והשלמת ערכים חסרים תוך כדי שדאגנו שלא תהיה דליפת מידע, יצרנו 18 פיצ'רים חדשים.

שם הפיצ'ר	סוג	תיאור
startYear	עמודה מקורית	שנת היציאה של הסרט
runtimeMinutes	נומריט-עמודה מקורית	משך הסרט בדקות
num_actors	נומריט-נגזרת מעמודת השחקנים הראשיים מהדאטה המקורית	מספר השחקנים הראשיים
num_genres	נומריט-נגזרת מעמודת הז'אנרים	מספר הז'אנרים שאליהם הסרט משויך
screen_time_per_actor	נומרי מורכב	יחס $runtime/num_actors$. סרט ארוך עם מעט שחקנים מצביע על אופי אחר מסרט קצר עם הרבה שחקנים.
director_oscar_wins	נומריט מסוג צבירה	מספר זכיות אוסקר של הבמאי לפני יציאת הסרט
lead_actors_oscar_wins	נומריט מסוג צבירה	סך זכיות אוסקר של השחקנים הראשיים לפני יציאת הסרט
lead_actors_oscar_wins_max	נומרי	המקסימום של זכיות אוסקר בקרב השחקנים - מזהה נוכחות כוכב מרכזי
actors_recent_movies_sum	נומריט מסוג צבירה	סך הסרטים שהשתתפו בהם השחקנים ב-5 השנים שלפני הסרט
actors_recent_movies_max	נומרי	המקסימום של פעילות שחקנים - מזהה שחקן עסוק במיוחד
has_director	בינארי	1 אם זהות הבמאי ידועה, 0 אחרת
is_sequel	בינארי	1 אם הסרט זוהה כסרט המשך לפי הכותרת (קיום מספר/Part/II וכיו')
missing_actors	בינארי	1 אם אין מידע על שחקנים. תופס דפוס Missing Not At Random - חוסר מידע אינו אקראי אלא מאפיין סוג סרט (תיעודי, אינדי).
missing_language	בינארי	1 אם אין מידע על שפה. מסמן סרטים נישתיים או הפקות עצמאיות.
missing_country	בינארי	1 אם אין מידע על מדינה. מאפיין סרטים נשכחים או מתעשיות קולנוע קטנות.
has_oscar_winner	בינארי	1 אם לפחות שחקן אחד זכה באוסקר לפני הסרט
actors_very_active	בינארי	1 אם יש שחקן עם +5 סרטים ב-5 שנים. סף ל-Binning של 'פעילות גבוהה' המבדיל בין שחקני 'יום-יום' לכוכבים מבוקשים.
decade	קטגוריאלי	העשור שבו יצא הסרט (1920s-2020s) - בינינג של startYear
genres	Multi-label	רשימת הז'אנרים של הסרט (מבין 28 ז'אנרים אפשריים)
Country	Multi-label	רשימת מדינות ההפקה (לאחר ניקוי וטיפול בישויות היסטוריות)
Language	Multi-label	רשימת שפות המקור של הסרט
director_name	טקסט	שם הבמאי - יקודד ב-Top 30 הבמאים הנפוצים

הדגשים על הנדסת הפיצ'רים

פיצ'ר ה- screen_time_per_actor: היחס בין משך הסרט למספר השחקנים בקאסט סרט באורך 180 דקות עם 3 שחקנים (60 דקות לשחקן) שונה מהותית מסרט באורך 90 דקות עם 30 שחקנים (3 דקות לשחקן) – פיצ'ר זה הוכיח הוא אחד מהמשפיעים והמסבירים במודל הוא קיבל מקום רביעי בחשיבות במודל ה-Random Forest.

פיצ'רי ה-missing_country, missing_language, missing_actors: חוסר מידע אינו תופעה אקראית בדאטה זה. סרטים תיעודיים, הפקות עצמאיות, וסרטים מתעשיות קולנוע קטנות נוטים להיות עם ערכים חסרים. פיצ'רים אלה מאפשרים למודל ללמוד שעצם החוסר הוא מאפיין משמעותי, בלי לאבד את הסרטים האלה מהאימון.

פיצ'ר ה- actors_very_active: מבצע מעבר מנומרי (actors_recent_movies_max) לבינארי באמצעות סף של 5 סרטים ב-5 שנים אחרונות. הסף הזה מבדיל בין שחקני 'יום-יום' לכוכבים מבוקשים – חלוקה שיש לה משמעות עסקית-תעשייתית מובהקת.

2. פונקציית prepare_data

פונקציית prepare_data אחראית באופן בלעדי על שלושה שלבים: ניקוי הדאטה הגולמית, הסרת עמודות מדליפות, והנדסת הפיצ'רים החדשים.

שלבי הפונקציה

1. **הסרת עמודות שמדליפות מידע עתידי**: הוסרו averageRating (משתנה המטרה), numVotes (מספר המצביעים מתעדכן באופן רציף לאחר השחרור), ו-BoxOffice (הכנסות הסרט - מידע שזמין רק לאחר השחרור).

הסרת עמודות לא תורמות: (~50%) plot ערכים חסרים, וטקסט חופשי שלא למדנו להתמודד במודלים).

primaryTitle (לאחר חילוף הפיצ'ר is_sequel ממנה).

Budget ערכים חסרים). (~87%

3. **העשרה ממקורות חיצוניים באמצעות שלושה קבצי cache שבנינו מראש**: imdb_enrich_cache (השלמת מדינה, שפה ובמאי מקבצי IMDb של title.akas, title.crew, ו-name.basics), oscar_wins_cache (זכיות אוסקר של שחקנים ובמאים ממסד הנתונים של Wikidata), ו-actor_movies_cache (היסטוריית סרטים של כל שחקן מקובץ title.principals).

4. **הנדסת 18 הפיצ'רים** - שתוארו בסעיף 1, תוך הקפדה שכל פיצ'ר היסטורי (אוסקרים, פעילות שחקנים) מחושב רק על אירועים שקדמו לשנת יציאת הסרט הנוכחי.

השלמת ערכים חסרים

עבור עמודות Country ו-Language נתקלנו באתגר, השדה region בקובץ title.akas של IMDb מציין טריטוריית הפצה ולא מדינת הפקה. סרט הוליוודי עם הפצה ב-100 מדינות יופיע בקובץ עם 100 שורות שונות. הגישה של 'לקיחת המדינה השכיחה ביותר' הובילה לתוצאות שגויות לחלוטין – לדוגמה, הסרט Justin Bieber's Believe תוג כהפקה לטבית.

בחרנו בגישה קשוחה הלוקחת מידע רק משורות עם סימון מפורש של מקור (isOriginalTitle=1 או types='original'). אם אין סימון מקור אמין, מחזירים None, והפיצ'ר missing_country/missing_language מקבל ערך 1. העדפנו NaN מפורש מאשר ערך משוער שגוי שיוביל לתוצאות מטעות.

בנוסף, יישמנו גישת STRICT WHITELIST עם רשימות מוגדרות מראש: כ-160 מדינות, כ-140 שפות, ו-28 ז'אנרים. כל ערך שאינו ברשימה נדחה. ישויות היסטוריות (Yugoslavia, Soviet Union) נשמרות בנפרד מהמדינות המקבילות שלהן היום, כדי שהמודל יוכל ללמוד את ההקשר ההיסטורי הייחודי שלהן.

3. מניעת Data Leakage

הסרת משתנים עתידיים ברמת הפיצ'רים

בשלב הראשון, הסרנו במכוון את כל המידע שלא היה זמין לפני שחרור הסרט. averageRating הוא משתנה המטרה ולכן חייב להיות מחוץ למאפיינים. אבל מעבר לכך, הסרנו גם משתנים שמתעדכנים אחרי השחרור: numVotes (מצטבר עם הזמן) ו-BoxOffice (נמדד אחרי השחרור).

גם בפיצ'רים שיצרנו, הקפדנו על העיקרון. director_oscars_wins סופר רק זכיות שהיו לפני שנת יציאת הסרט – לא אוסקרים עתידיים שהבמאי זכה בעקבות סרטים מאוחרים. אותו עיקרון חל על lead_actors_oscars_wins ועל actors_recent_movies שמסתכלים רק על חלון של 5 שנים שקדם לסרט הנוכחי.

Cross-Validation בתוך Pipeline :

יצרנו Pipeline שמכיל את כל שלבי ה-imputation, ה-scaling וה-encoding כחלק בלתי נפרד מהמודל. בקריאה ל-cross_validate, Scikit-Learn מבצע אוטומטית את כל שלבי הלמידה מחדש בכל fold – על נתוני האימון של אותו fold בלבד. סט המבחן מקבל את הטרנספורמציה שנלמדה אך לא משפיע עליה.

ColumnTransformer בתוך ה-Pipeline מנתב כל קבוצת פיצ'רים לטיפול המתאים לה: פיצ'רים נומריים מקבלים SimpleImputer(strategy='median') ואז StandardScaler (רק במודל הליניארי); פיצ'רים קטגוריאליים מקבלים SimpleImputer(strategy='most_frequent') ואז OneHotEncoder עם max_categories=30; פיצ'רי multi-label מקבלים MultiLabelTopN מותאם שלמדנו ל-25 הערכים השכיחים בכל עמודה. כל זה – בנפרד בכל fold.

4. השוואת שני המודלים (10-Fold Cross-Validation)

הערכנו שני מודלים שונים מהותית – Elastic Net (רגרסיה ליניארית עם רגולריזציה משולבת L1+L2) ו-Random Forest. ההערכה הסופית בוצעה ב-10-Fold Cross-Validation

מודל	RMSE	± Std	MAE	± Std	R ²	± Std
Elastic Net	1.1229	0.0140	0.8582	0.0111	0.2474	0.0126
Random Forest	1.0873	0.0153	0.8290	0.0118	0.2944	0.0124

ניתוח התוצאות

Random Forest עולה על Elastic Net בכל שלושת המדדים: שיפור של 3.2% ב-RMSE, 3.4% ב-MAE, ו-19% יחסית ב-R². ההפרש מובהק סטטיסטית – הוא גדול בהרבה מסטיות התקן של כל מדד בנפרד.

שני המודלים מציגים יציבות גבוהה לאורך ה-10 folds, עם סטיית תקן של 1.2%–1.4% מהממוצע ב-RMSE. יציבות זו מצביעה על כך שהמודלים לומדים דפוסים אמיתיים בדאטה ולא משתעבדים לפרטים מקריים של חלוקה ספציפית.

5. ניתוח חשיבות פיצ'רים

חילצנו את חשיבות הפיצ'רים מ-Random Forest באמצעות מדד MDI (Mean Decrease Impurity) המובנה במודל. מדד זה מסכם עבור כל פיצ'ר את ההפחתה הממוצעת ב-Variance של תחזיות העץ, משוקללת לפי שכיחות השימוש בפיצ'ר ברחבי כל העצים שביער. הטבלה מציגה את חמשת הפיצ'רים החשובים ביותר.

סוג	חשיבות (MDI)	שם הפיצ'ר	דירוג
נומרי	0.1048	runtimeMinutes	1
קטגוריאלי	0.1032	genres=Documentary	2
קטגוריאלי	0.1001	genres=Horror	3
נומרי (הנדסי - Ratio)	0.0938	screen_time_per_actor	4
נומרי	0.0705	startYear	5

ז'אנר הוא הגורם הדומיננטי: שני הז'אנרים Documentary ו-Horror מופיעים במקומות 2 ו-3, ויחד תופסים כמעט 20% ממשקל ההחלטות של המודל. סרטי Documentary נוטים לציונים גבוהים מהממוצע, כנראה כיוון שהם מבוקרים בעיקר על-ידי קהל יעד מעורב, בעוד שסרטי Horror סובלים מפיזור גדול באיכויות ההפקה ונמוכים בממוצע.

Runtime הוא המנבא הבודד החזק ביותר: עם חשיבות של 10.5%, runtimeMinutes הוא הפיצ'ר היחיד שעוקף את הז'אנרים. הסיבה: אורך הסרט מקודד מידע על תקציב, אמביציה, וסוג הקהל המיועד. סרטים ארוכים מאוד הם לרוב הפקות גדולות או יומרניות אקדמיות.

screen_time_per_actor: הפיצ'ר ההנדסי שיצרנו, נמצא במקום הרביעי עם חשיבות של 9.4%. זוהי הוכחה מפורשת לכך שיחס בין שני פיצ'רים גולמיים יכול ללכוד מידע שלא נמצא באף אחד מהם בנפרד. ה-RF זיהה את חשיבותו של היחס, גם בלי שנציינו לו במפורש לחפש אותו.

StartYear: השנה במקום החמישי משקפת מגמות תקופתיות – שינויים בטעם הקהל, התפתחות התעשייה, ושינויים בקריטריוני ההצבעה ב-IMDb עצמה. נדון בעניין זה לעומק בסעיף הוגנות.

6. ניתוח שגיאות (Error Analysis)

חילצנו את 20 הסרטים שהמודל הכי טעה בהם באמצעות cross_val_predict – מנגנון שמייצר תחזיות לכל סרט מהמודל שאומן על שאר הסרטים, ובכך מאפשר זיהוי outliers אמיתיים ולא overfitting. הניתוח מציג את 5 הטעויות הגדולות ביותר בכל כיוון.

5 סרטים עם Overprediction הגדול ביותר

שגיאה	חזוי	אמת	ז'אנר	שנה	שם הסרט
-6.02	7.32	1.30	Documentary	2019	Tribalism Is Killing Us
-5.95	7.15	1.20	Documentary	2023	Kurz
-5.81	7.31	1.50	Documentary	2010	Obama in NC
-5.60	7.20	1.60	Documentary	2000	Hatemongers
-5.34	6.94	1.60	Music ,Documentary	2013	Justin Bieber's Believe

5 סרטים עם Underprediction הגדול ביותר

שגיאה	חזוי	אמת	ז'אנר	שנה	שם הסרט
+4.37	4.73	9.10	Thriller ,Horror	2011	Son-nim Cheo-beon-jjae
+4.37	4.73	9.10	Horror ,Action	2012	Bukunja Tekunja Mitti
+4.35	5.25	9.60	Thriller ,Romance	2015	Of Sound Mind
+4.28	5.12	9.40	Thriller	2023	Il Santo Veleno
+4.10	5.40	9.50	Comedy	2023	Gud förbannat

דפוסים שזיהינו

דפוס Overprediction – תיעודיים פוליטיים ושיווקיים: ארבעה מתוך חמשת הסרטים שהמודל חזה להם דירוגים גבוהים מדי הם סרטי Documentary. המודל למד שתיעודיים זוכים בממוצע לדירוגים גבוהים, אך הוא לא מבדיל בין סרטי תעודה איכותיים לבין שני סוגים שמקבלים דירוגים נמוכים מאוד:

הסוג הראשון – תיעודיים פוליטיים שעוברים Review-Bombing: סרטים כמו Tribalism Is Killing Us, Hatemongers ו-Obama in NC עוסקים בנושאים פוליטיים שנויים במחלוקת. הקהל המתנגד מצביע בכוונה ציונים נמוכים מאוד (1, 2) כצורה של פעילות פוליטית, מה שמשפיל את הציון הממוצע באופן מוטה. המודל לא יכול לזהות את הדפוס הזה כי הוא רואה רק 'Documentary' – לא את הטעינות הפוליטית של הכותרת.

הסוג השני – תיעודיים שיווקיים סביב סלבריטאים: Justin Bieber's Believe הוא סרט שיווקי שמוכר אישיות פופ. הוא מקבל דירוגים מאוד נמוכים מהקהל הכללי (1.6) למרות הקטגוריזציה כ-Documentary. גם כאן, המודל רואה רק את הקטגוריה ולא את האופי השיווקי.

דפוס Underprediction – סרטי אימה וסרטי הינדי עם Cult Following : ארבעה מתוך חמשת ה-Underpredictions הם סרטי Thriller, Horror או הפקות נישתיות. כאן הדפוס הוא הפוך – המודל למד ש-Horror בכללי מקבל דירוגים נמוכים, אבל לא יכול לזהות סרטים נישתיים שזכו ל-Cult Following של קהל קטן ומסור שמדרג אותם +9.

Gud förbannat ו-Of Sound Mind הם דוגמאות לסרטים שמשכו קהל מיוחד שמדרג אותם גבוה מסיבות שלא נראות במטה-דאטה – הומור מקומי, מוצא תעשייתי שונה, או אלמנט פולחני שלא ניתן ללכוד מתכונות הסרט הבסיסיות.

המסקנה : המודל מצליח ללמוד דפוסי ממוצע של ז'אנרים, אך מתקשה לטפל ב-Outliers שמופיעים בקצוות של ההתפלגות מסיבות חיצוניות – פעילות פוליטית, התלהבות פולחנית, או שיווק. אלה תופעות שדורשות מידע מחוץ למטה-דאטה, כפי שנציע בסעיף המסקנות

7. ניתוח הוגנות (Fairness Analysis)

בחנו האם מודל ה-Random Forest מציג ביצועים הוגנים על פני קבוצות שונות של סרטים, או שהוא 'מפלה' לרעה תת-קבוצות מסוימות. עבור כל תת-קבוצה חישבנו את ה-RMSE בנפרד והשוונו אותו לממוצע הכללי (1.077). פערים גדולים מצביעים על בעיות הוגנות.

חתי 1: לפי ז'אנר

הם הז'אנרים שהמודל מתפקד בהם הכי טוב – פערים של 8%–9% מתחת לממוצע. Action הוא הז'אנר הקשה ביותר (RMSE=1.15, +7%), כנראה בגלל הגיוון הגדול בתת-ז'אנרים – מסרטי גיבורי-על מיינסטרים ועד B-movies בתקציב נמוך. הפער הכולל בין הז'אנר הכי טוב לגרוע הוא 17% – לא דרמטי, אך משמעותי.

חתי 2: לפי מדינה (US לעומת Non-US)

המודל מתפקד טוב יותר על סרטים אמריקאיים (RMSE=1.00) מאשר על (Non-US (RMSE=1.10 – פער של 10%. ממצא זה מעניין במיוחד מאחר שיש פי 3 יותר סרטי Non-US בדאטה (60,210 לעומת 20,682). הסיבה הסבירה: התעשייה ההוליוודית הומוגנית יותר, עם פרמטים סטנדרטיים וקשרים מובהקים בין מטה-דאטה לדירוג. תעשיות הקולנוע הלא-אמריקאיות, לעומת זאת, כוללות מגוון רחב של מסורות (בוליווד, סינמה אסיאתית, אירופאית) – כל אחת עם דינמיקות דירוג שונות שקשה להציג כקטגוריה אחת.

חתי 3: לפי עשור

הערכה	% סטייה מהממוצע	RMSE	מס' סרטים	עשור
מצוין	-29%	0.76	2,359	1940s
טוב	-13%	0.94	4,350	1960s
בינוני	-6%	1.02	6,759	1980s
בינוני	+3%	1.11	12,257	2000s
חלש	+11%	1.20	12,712	2020s

הממצא הדרמטי ביותר בכל ניתוח ההוגנות: יש פער של 57% בין שנות ה-40 (הביצועים הטובים ביותר) לבין שנות ה-2020 (הביצועים הגרועים ביותר). הסיבה אינה כמות הדאטה – לשנות ה-2020 יש פי 5 יותר סרטים. הסיבה היא Survivorship Bias: סרטים ישנים ששרדו ב-IMDb הם הקלאסיקות שזכרו, וכולם בעלי איכות עקבית גבוהה. סרטים חדשים, לעומת זאת, כוללים את כל הספקטרום – מ-Blockbusters ועד הפקות יו-טיוב חובבניות שעלו לדאטה.

דין בחששות הוגנות

המודל יחסית הוגן בחתכי הז'אנר והמדינה (פערים מתונים). אבל הוא מציג בעיית הוגנות משמעותית בחתך העשור – ספציפית, הוא פחות אמין על סרטים חדשים. עבור שימוש מסחרי בחיזוי דירוגי סרטים עתידיים, מומלץ:

- להוסיף 'אזהרת אמינות' לסרטים מהעשור הנוכחי – המודל אמין יותר על קלאסיקות
- לא לסמוך על המודל כשמדובר בז'אנר Horror או Documentary עם תוכן פוליטי – פערים גדולים בכיוונים מנוגדים
- עבור סרטים Non-US, כדאי להוסיף פיצ'רים נוספים שיתאימו לתעשיית היעד הספציפית

8. מסקנות, מגבלות והצעות להמשך

מסקנות עיקריות

- מודלים מבוססי עצים מתאימים יותר לחיזוי דירוגי סרטים מאשר מודלים ליניאריים. Random Forest השיג $R^2=0.2944$ לעומת 0.2474 ב-Elastic Net – שיפור של 19% יחסי.
- ז'אנר הוא הפיצ'ר הדומיננטי – Documentary (חיובי) ו-Horror (שלילי) הם שני המנבאים החזקים ביותר. ההסכמה בין שני המודלים על נקודה זו מחזקת את האמינות.
- הנדסת פיצ'רים תרמה משמעותית: Ratio (screen_time_per_actor) נמצא במקום הרביעי בחשיבות, ופיצ'רי ה-MNAR הוכיחו את ערכם בלכידת דפוסים שלא ניתנים לתפיסה מנתונים גולמיים.
- המודל מציג מגבלות בולטות בסרטים חדשים (פער של 57% מהממוצע ב-2020s), בסרטים פוליטיים, ובסרטים נישתיים עם Cult Following.

מגבלות מהותיות

חיזוי דירוגי IMDb לפני שחרור הסרט הוא משימה עם תקרה תיאורטית. הציון הסופי נקבע על-ידי תופעות חברתיות-תרבותיות שלא ניתן לחזות מהמטה-דאטה: באז ברשתות חברתיות, תגובות מבקרים, מגמות פוליטיות, ואיכויות אומנותיות סובייקטיביות. R^2 של 0.30 על מטה-דאטה בלבד הוא תוצאה סבירה בספרות האקדמית בתחום.

הצעות להמשך

ניתוח טקסט (NLP) על תקציר העלילה: שדה ה-plot שהוסר עקב חוסר ב-50% מהנתונים מכיל מידע פוטנציאלי רב. עיבוד באמצעות מודלים כמו BERT או GPT לחילוץ embeddings סמנטיים יכול ללכוד את 'אופי' הסרט – לדוגמה, להבדיל בין דרמה פוליטית קלילה לדרמה פוליטית טעונה.

מדדי באז לפני שחרור (Pre-release Hype): מטריקות חברתיות כמו ספירת אזכורים ב-Twitter/X, חיפוש ב-Google, צפיות ב-YouTube, ופעילות בפורומי קהל יכולות לתת אינדיקציה לעניין מוקדם – מנבא חזק של דירוגים מאוחרים.

ניתוח sentiment של ביקורות מוקדמות: מבקרי קולנוע מפרסמים ביקורות עוד לפני השחרור הרשמי. ניתוח רגשי של ביקורות מוקדמות מ-Rotten Tomatoes או Metacritic יכול לתת חיזוי קצר-טווח בעוצמה גבוהה.

9. AI Usage Log – שקיפות בשימוש בכלי בינה מלאכותית

השתמשנו במודלי שפה בעיקר Claude ונוטבוק אל אם בשלבים מסוימים של הפרויקט.

שלבים שבהם השתמשנו Claude

- התייעצות ראשונית להנדסת פיצ'רים – התייעצנו אילו יחסי פיצ'רים (Ratios) ואינדיקטורים (Binnings) עשויים להיות רלוונטיים, בהתבסס על הבנת התחום ועקרונות מהקורס.
- Refactoring של הקוד למבנה Pipeline של Scikit-Learn – הקלוד עזר במבנה הטכני של ColumnTransformer ובמתודולוגיה הנכונה למניעת Data Leakage.
- דיבאג של בעיות הקשורות להעשרת נתונים מ-IMDb – זיהוי שגיאת המתודולוגיה בטיפול בשדה region של title.akas, ופיתוח הלוגיקה השמרנית של בחירת country רק משורות מסומנות כמקור.
- הסבר רעיוני של מושגים מתקדמים לשיפור המודל – PolynomialFeatures, אסטרטגיות Grid Search, ושימוש ב-outliers cross_val_predict.

מה לא נעשה על-ידי LLM

ההחלטות המתודולוגיות, הניתוח האנליטי של התוצאות, וההסקות המדעיות הם תוצר של עבודה עצמאית שלנו. ה-LLM שימש ככלי עזר טכני ולשוני – בדומה לחיפוש ב-Stack Overflow או התייעצות עם מתרגל. כל ההבנה התיאורטית, פירוש התוצאות, וההצעות לעבודה עתידית מבוססות על החומר שנלמד בקורס ועל ניתוח הנתונים שלנו.